

特征融合与 objectness 加强的显著目标检测

王娇娇, 刘政怡, 李辉

WANG Jiaojiao, LIU Zhengyi, LI Hui

安徽大学 计算机科学与技术学院, 安徽 合肥, 230601

College of Computer Science and Technology, anhui university, 230601, China

WANG Jiaojiao, LIU Zhengyi, LI Hui. Feature fusing and objectness enhanced approach of saliency detection

Abstract: Saliency detection is a fundamental part of computer vision applications, and the goal is to detect important pixels or regions in an image which attracts human visual attention most. By analyzing some recent methods, a new approach is proposed to solve detection errors problems and to enhance the adaptation of features in saliency detection. It detects saliency in the perspective of both object and background and integrates multi features. It extracts color distinctness feature in the perspective of object and extracts boundary prior feature in the perspective of background, and then combines the two features to obtain the corresponding map. In order to keep accuracy, it uses objectness feature to refine the saliency of detected regions. In comparison experiments, it achieves an average precision of 92.4% on MSRA-1000 databases, and achieves higher precision on CSSD dataset and ECSSD dataset. Experimental results demonstrate the used features make up for each other, which can enhance the saliency detection accuracy.

Key words: computer vision; saliency detection; boundary prior; color distinctness; objectness

摘要: 显著目标检测是计算机视觉的重要组成部分, 目的是检测图像中最吸引人眼的目标区域。针对显著检测中特征的适应性不足以及当前一些算法出现多检与漏检的问题, 提出从“目标在哪儿”与“背景在哪儿”两个角度描述显著性的框架, 进行特征融合来提高显著目标检测的准确率。从这两个角度分别提取图像的颜色区别性特征与边界先验特征并进行特征融合, 使用 objectness 特征加强显著性, 最终得到显著图。在 MSRA-1000 数据集上的评估中, 本文算法达到平均 92.4% 的准确率, 能和最先进算法相媲美; 而在 CSSD、ECSSD 数据集上的实验, 本文算法有更高的准确率, 优势明显。实验表明所使用的特征之间能够互相补充, 互相弥补, “目标在哪儿”与“背景在哪儿”的检测框架描述图像显著性具有合理性。

关键词: 计算机视觉; 显著目标检测; 边界先验; 颜色区别性; objectness

doi:10.3778/j.issn.1002-8331.1504-0287

中图分类号: TP391

文献标志码: A

1 引言

人类视觉能够在一个场景中迅速捕获感兴趣的位置, 显著目标检测模拟人眼视觉检测图像中最重要、最有信息的部分。正确提取这些重要目标区域可以大大提高图像处理与分析的效率和正确性,

它可以应用在大量的视觉问题上, 如图像分割、目标识别、图像压缩, 以及基于内容的图像检索等研究。显著检测的重要性吸引了研究者们广泛的关注, 近来人们提出了很多算法。

但由于缺乏高层知识, 大多算法依赖于图像的属性特征。早期的方法都是属于基于图像属性对比

基金项目: 高等学校博士学科点专项科研基金联合资助课题(20133401110009); 安徽高校省级自然科学基金项目(KJ2015A009)


作者简介: 王娇娇(1990-), 女, 硕士研究生, 主要研究方向为智能图像识别; 刘政怡(1978-), 女, 副教授, 博士, 从事方向领域为人工智能、图像处理; 李辉(1991-), 男, 研究生, 主要研究方向为人工智能。E-mail:331926854@qq.com

度特征的显著检测,如 Koch 和 Ullman 在文献[1]里提出基于底层特征对比度的中心-周围模型。Itti 在文献[2]中提及高斯差分方法的图像显著检测。受这些思想的启发,人们提出了大量的延伸算法。文献[3]在频域检测显著目标;文献[4]使用基于全局对比度的计算方法;文献[5]以及文献[6]提出检测有区别性的图案;文献[7]基于图像颜色对比度计算每个像素的显著性;文献[8]将 Itti 等人的特征图归一化来突出显著部分。

近来一些新的方法提出使用边界先验知识。文献[9]假定图像边界接触的图像块都是背景;文献[10]将与图像边界的对比度作为学习的特征;文献[11]提出图像的 4 个边界通常都是背景区域的先验知识,将图像边界假定为背景。这些方法都是健壮的,因为它们描述了图像关于边界的空间布局,这种特征对图像有一个直观的几何描述,即使图像内容发生变化也有很好的稳定性,这种独特的优势是之前提出的算法中所没有的,可以用来加强传统对比度方法的计算。

文献[12]中 Borji 等在 5 个数据集上比较了当前最先进的算法,发现将已有算法的一些特征结合起来会增强显著检测的准确性,因为不同的算法是针对不同问题建立在不同假设上的,它们的结合可能会提高显著检测的准确性。但另一方面,他们的实验结果还显示简单的把特征相结合有时也并不能保证提高显著检测的准确性,这表明那些广泛使用的特征之间可能并不能互相补充,相反,甚至是互相排斥的。

本文提出“目标在哪儿”、“背景在哪儿”的检测框架,融合颜色区别性特征、边界先验以及 objectness 特征。实现对比度特征与边界先验知识的互相弥补,同时使用 objectness 特征来保持检测到的显著区域的准确性。图 1 所示是本文算法的实例。



依次:原图,颜色区别性,边界先验,objectness,特征融合,模板

图 1 本文方法实例

2 对比度特征与边界先验

显著性源于视觉的独特性、不可预测性,这是由颜色、梯度、边缘、边界等图像属性所致,因而传统的显著目标检测算法大多是依赖于图像属性特征的自底向上的显著检测,这些算法最广泛使用的假设就是目标和它周围区域对比度很高,这样的假设称作对比度特征。具体来说就是利用亮度、颜色、边缘等底层特征属性来决定图像某个区域和它周围的对比度。这些方法直接从显著目标应该具有的特征出发,检测显著目标。但是由于目标之间的行为差异,对比度适应性不足,虽然人们提出了很多计算模型,但是很难适用于所有情况。一些算法使用颜色对比度特征,如对于图 2(a)所示的输入图像,CB^[13]方法错误地把背景中的两个黑块也检测为显著目标,结果如图 2(b)所示。可见这种方法并不是十分有效的,因为一些具有区别性颜色的区域有时并不是显著区域。

除了对比度特征,最近一些新的研究采用边界先验知识的方法,也就是说图像的边界大多数都是背景,用来加强显著计算。它是从背景的角度出发,指出背景应该具有的特征,进而剔除背景而更精确地检测出前景。利用这种假设的一些算法甚至达到了最先进结果,这表明利用边界先验知识的方法是有效的。然而当图像的目标和边界有一点点接触,或者目标和边界具有相似性时就会出现误差,有时候甚至丢失目标。如对于图 2(a)所示的输入图像,MR^[11]方法检测结果如图 2(c)所示,出现了目标漏检。




图 2 显著目标检测

3 本文方法

本文算法的一个指导思想就是从“目标在哪儿”、“背景在哪儿”两个角度描述图像的显著性。传统对比度特征是从正面描述目标的方法,具有一定的局限性不能适用于所有情况。所以从反面出发增加描述背景的特征,并将背景剔除来补充正面描述目标特征的不足。算法流程如图3所示。

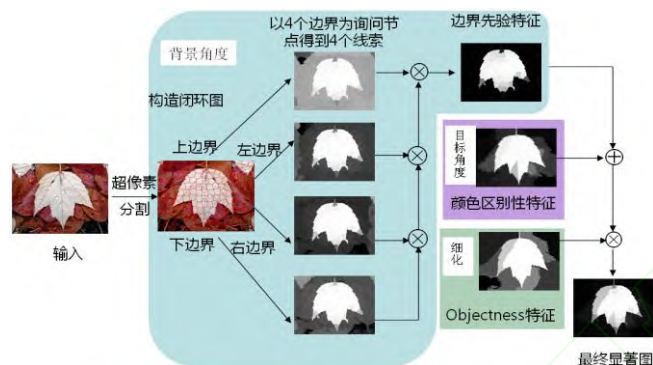


图3 本文方法流程图

通过观察可知,显著目标和周围目标相比是具有颜色区别性的,它具有颜色区别性特征。其次,从几何构图的角度来看,图像背景是位于图像边界部分的,因而可以提取背景特征进而剔除背景信息得到更精确的前景。针对边界先验知识方法出现漏检的问题,使用颜色区别性特征来补充显著性特征,而边界先验知识也能在一定程度上弱化具有颜色区别性但不是目标的区域的显著性。另外,为进一步考虑显著目标的准确性,使用 objectness 特征加强显著性。下面详细介绍本文算法。

3.1 边界先验——“背景在哪儿”

自然图像中目标和背景在空间分布上是截然不同的,目标区域和背景区域相比,很少接触到图像边界。那么,就可以做出这样的假设,把图像的4个边界当做背景,通过相关性比较,找出图像中背景、目标的大致分布。

文献[14]提出流行性排序算法,它利用数据(或图像)的内在流行结构获得类别标签。根据这种分类的思想,可以对图像内容进行分类,并将分类的结果分别标记为背景、目标。给定一个数据集 $X = \{x_1, \dots, x_i, x_{i+1}, \dots, x_n\} \in R^{m \times n}$, 其中一些数据点标记为询问节点,其余根据它们和询问节点的相关性排序。令 $f: X \rightarrow R^n$ 表示排序函数,给 x_i 分配一个排序值 f_i 。 f 可以看做一个向量 $f = [f_1, \dots, f_n]^T$, 令

$y = [y_1, y_2, \dots, y_n]^T$ 为指示向量, $y_i = 1$ 表示 x_i 是询问节点, $y_i = 0$ 反之。随后构建一个图 $G = (V, E)$, 节点 V 代表集合 X , 边 E 由一个关联矩阵 $W = [w_{ij}]_{n \times n}$ 加权, 给定 G , 次数矩阵即为 $D = \text{diag}\{d_{11}, \dots, d_{nn}\}$, $d_{ii} = \sum_j w_{ij}$ 。询问的最优排序通过最优化下面的公式解决:

$$f^* = \arg \min_f \frac{1}{2} \left(\sum_{i,j=1}^n w_{ij} \|f_i / \sqrt{d_{ii}} - f_j / \sqrt{d_{jj}}\|^2 + \mu \sum_{i=1}^n \|f_i - y_i\|^2 \right) \quad (1)$$

μ 控制平滑限制和拟合约束的平衡,也就是说一个好的排序算法,要使邻近节点之间相关性变化不大。本文算法使用一个非归一化拉普拉斯矩阵得到排序函数:

$$f^* = (D - \alpha W)^{-1} y \quad (2)$$

图像显著检测中,首先要把图像构建为图结构。使用 SLIC^[15]算法,把图像分割为超像素,每个超像素为一个节点。因为相邻节点可能有相似的形状及显著值,因此使用 k-正则图表示节点间的空间关系。首先,设置每个节点不仅和相邻节点连接,还和有公共边的节点连接,以这样的方式将节点的度扩展为 k。其次,把图像的四边当做是连接的,边界上的每一对节点也视作毗邻的。这样得到一个闭环图,如图4所示,图中所示边界中的紫色线条表示边界各节点是互相连接的。




图4 超像素分割,构造闭环图

本文依次把4个边界所包含的节点当做询问节点,通过流行性排序算法,得到4个关于目标与背景分布图,然后再将4个图整合,得到最终的显著图。以左边界为例,先把左边界的节点当做询问节点,其他节点为数据,指示向量 y 就是固定的了,其他所有节点根据公式2排序, f^* 是一个 N 维向量 (N 表示图中所有节点的个数)。向量中每个元素表示该节点和询问节点的相关性,然后对向量进行归一化处理,使向量中的值在0到1之间,即 \bar{f}^* , 得到显著图:

$$S_{li}(i) = 1 - \bar{f}^*(i) \quad i = 1, 2, \dots, N, \quad (3)$$

其中 i 表示图中的超像素节点, 类似的得到其他 3 个显著图, 使用公式(4)把它们整合, 得到显著图, 标记为 S_b 。

$$S_b(i) = S_{ip}(i) \times S_{br}(i) \times S_{lt}(i) \times S_{rn}(i) \quad (4)$$

3.2 颜色区别性——“目标在哪儿”

显著目标总是跟它周围背景具有明显的颜色区别性, 但由于缺乏对显著目标大小的认知, 先前的研究采用高斯金字塔的方法, 这是一种通用的多尺度显著检测方法。根据这样的思想, 本文在多超像素尺度上进行显著检测, 将像素级计算量减少为区域(超像素)的计算量。

把图像 I 分割成区域 $\{r_i^{(n)}\}_{i=1}^{R(n)}$, 对给定区域 $r_i^{(n)}$ 它的空间邻近区域为 $\{r_k^{(n)}\}_{k=1}^{K(n)}$, $r_i^{(n)}$ 的显著定义为:

$$S(r_i^{(n)}) = -w_i^{(n)} \log \left(1 - \sum_{k=1}^{K(n)} \alpha_{ik}^{(n)} d_{color}(r_i^{(n)}, r_k^{(n)}) \right) \quad (5)$$

这里 $\alpha_{ik}^{(n)}$ 是区域 $r_k^{(n)}$ 大小和 $r_i^{(n)}$ 周围所有相邻区域大小的比值, $d_{color}(r_i^{(n)}, r_k^{(n)})$ 是区域 $r_i^{(n)}$ 和 $r_k^{(n)}$ 之间的颜色距离, 即这两个区域的 CIE Lab 和色调直方图之间的 χ^2 距离。

其次, 当目标越接近图像中心越可能是显著目标, 考虑到这一点, 采用高斯下降权重模型, 定义为:

$$w_i^n = \exp(-\frac{\|x_i - c\|^2}{2\sigma^2}) \quad (6)$$

w , h 分别表示图像的宽度和长度, $(dx_i^{(n)}, dy_i^{(n)})$ 是区域 $r_i^{(n)}$ 中所有像素和图像中心之间的平均空间距离。

最终, 把区域的显著值扩展到像素级, 这样的扩展让显著检测在复杂环境下计算得更健壮, 能实现更好的性能。像素 p 的显著值定义为:

$$S_m(p) = \frac{\sum_{n=1}^N \sum_{i=1}^{R(n)} S(r_i^{(n)}) (\|I_p - c_i^{(n)}\| + \varepsilon)^{-1} \delta(p \in r_i^{(n)})}{\sum_{n=1}^N \sum_{i=1}^{R(n)} (\|I_p - c_i^{(n)}\| + \varepsilon)^{-1} \delta(p \in r_i^{(n)})} \quad (7)$$

i 表示第 i 区域, n 表示超像素级别, N 表示超像素分割尺度, ε 是常数, $c_i^{(n)}$ 是区域 $r_i^{(n)}$ 的颜色中心, $\|I_p - c_i^{(n)}\|$ 是像素 p 到颜色 $r_i^{(n)}$ 的中心的颜色距离, $\delta(\cdot)$ 是指示函数。并将得到的最终结果标记为 S_c 。

3.2 objectness 特征

objectness 是 Alexe 等在文献[16]中提出, 表示一个像素或区域包含完整目标的可能性。人眼倾向于完整的去识别一个目标是否显著, 因此评估每个区域是否属于可识别区域, 并优先考虑可识别区域为显著区域的方法是合理的。根据文献[16], 一个图像中所含目标通常包含下面特点: 1) 包含一个空间闭合的边界; 2) 和周围事物有不同的形态; 3) 有时是独特、突出的。

这些特点和显著的概念大体上一致, 因此可以使用图像的 objectness 特征来评估显著性。考虑到要保持目标的区域完整性, 这里使用 mean-shift 分割算法分割图像区域保持每个目标的 objectness 特征具有一致性。其次计算 objectness, 过程分为两步: 评估像素级 objectness 和区域级 objectness。

计算每个像素的 objectness 特征, 需要在图像上随机分布 N 个窗口, 每个窗口 w 用文献[16]的方法计算 objectness 得分, 并记为 $P(w)$ 。随后对所有窗口 W , 统计包含每个像素点的窗口的 objectness 得分, 以此获取每个像素的 objectness 特征, 公式如下:

$$O_p(x) = \sum_{w \in W \cup x \in w} P(W_x) \quad (8)$$

其中 w 表示 W 中任意包含像素 x 的窗口。实验中 N 设置为 10000。其次, 计算每个区域 Λ_i 的 objectness 特征:

$$O_r(\Lambda_i) = \frac{1}{|\Lambda_i|} \sum_{x \in \Lambda_i} O_p(x) \quad (9)$$

计算出所有区域的 objectness 特征后, 将特征值分配到区域所包含的像素上。最后, 得到整个图像的 objectness 特征, 标记记为 O 。

3.2 结合

沿着“目标在哪儿”+“背景在哪儿”的检测框架, 融合边界先验与颜色区别性。即对边界先验和颜色区别性特征进行或操作。或操作可以保持两种特征检测到的显著性区域的完整性, 防止出现漏检的现象。同时利用边界先验的健壮性弥补颜色区别性因适应性不足出现的误检错误; 利用颜色区别性特征来弥补边界先验特定情况下出现漏检的错误。从两种角度描述显著目标, 可以结合两者的优势获得完整的显著目标区域。

其次, 为了使检测的区域更加精确, 需要对检

测的显著目标区域进行细化,以防止出现多检的现象。并使用 objectness 特征做与操作,与操作可以对显著区域进行约束,使检测到的区域更加精细。图 5 所示是本文算法的一个实例。这里使用一个指数函数来加强与计算。公式 10 定义最终的显著值 S 的计算:

$$S = (S_b + S_c) \cdot \exp(O) \quad (10)$$




图 5 特征融合

4 实验

实验分别在 3 个数据集上评估本文算法,数据集包括: MSRA-1000^[12]、C SSD^[17]、ECSSD^[17], 分别评估 Precision, Recall, F-measure 这 3 个指标。实验对比本文方法使用的各项特征即边界先验、颜色区别性、objectness 单独使用的特征指标和特征融合的方法指标,同时比较本文算法和其他算法。对比算法选用当前最先进算法中的 6 种,包括: MR^[11], HS^[17], AMC^[18], PCA^[19], GS-SP^[9], SF^[20]。

实验平台: 所有程序都是在 Pentium(R) Dual-Core CPU(E5500) 2.80GHz 内存 2GB 的 PC 上实现,使用 MATLAB (R2010b),对比算法来自作者提供的公开代码。

4.1 数据集

MSRA-1000: 该数据集是 MSRA 数据集的子集,它包含 1000 张图像的测试集,并由人工精确标注了显著区域。

C SSD: C SSD 数据集包含 200 张图像,并有人工标记的显著目标模板, MSRA 数据集有大量不同内容的图像,但背景结构一般都比较简单。C SSD 包含各种不同图案的背景、前景,更能代表自然图像的一般情况。

ECSSD: 该数据集是 C SSD 数据集的扩充,包含 1000 张精确标注显著区域图像,相对来说更有

挑战性,更接近自然图像。

4.2 评估标准

给定显著图,采用 3 个标准来评估不同方法的量化性能: Precision、Recall、F-measure,并绘制 Precision-Recall 曲线(PR 曲线)以及各指标的直方图。具体地, Precision 表示正确分配到提取区域中显著像素的比例, Recall 表示定义为显著像素关于模板数量的比例。PR 曲线是通过把显著图二值化得到的,使用的阈值范围在[0,255]之间。

Precision 计算公式为:

$$P = \sum_x g_x a_x / \sum_x a_x \quad (11)$$

Recall 计算公式为:

$$R = \sum_x g_x a_x / \sum_x g_x \quad (12)$$

F-measure 的计算公式为:

$$F = ((\beta^2 + 1)P \cdot R) / (\beta^2 P + R) \quad (13)$$

其中, $\sum_x g_x$ 为基准二值图; $\sum_x a_x$ 为检测结果的二值图; $\beta^2 = 0.3$, 和文献[12]建议的设置保持一致。




图 6 评估本文方法使用的各项特征


4.3 实验结果

4.3.1 评估各项特征

图 1 所示是使用本文方法检测显著目标的例子。算法融合了颜色区别性特征和边界先验特征,以及 objectness 特征,最终检测结果接近于模板。图 6 所示是在 MSRA-1000 数据集上测试各项特征所绘制的 PR 曲线,包括单独使用各项特征的曲线,以及特征相结合的曲线。 S_b 边界先验特征曲线, S_c 表示颜色区别性特征曲线, O 表示表示 objectness 特征曲线。从图中可以看出,颜色区别性特征和边界先验特征的结合,要比单独使用这两种特征的准确率要高,可见这两种特征是能互相补充的,同时 objectness 特征的使用也提高了显著性的准确率,最终方法的性能更优越。

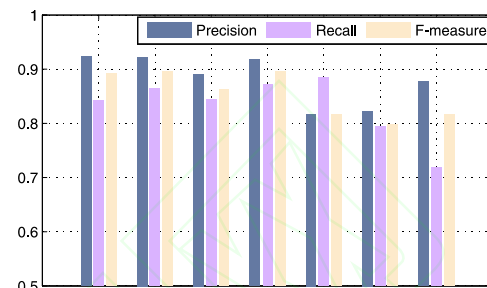
4.3.2 MRSA-1000 数据集

图 7(a)所示是本文算法在 MRSA-1000 数据集上的实验对比结果。从绘制的 PR 曲线上看, 本文算法在某些区域和 MR、AMC 算法的曲线有接触,



(a) PR 曲线

但整体上看本文算法更优越。图 7(b)所示 Precision, Recall, F-measure 的 3 个指标的评估, 本文算法和 MR、AMC 算法的指标评估水平相当, 但准确率略高些。

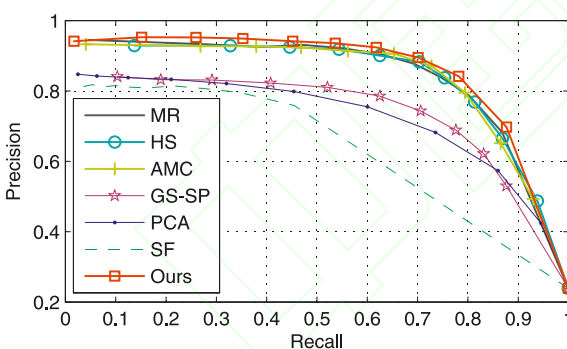


(b) 指标直方图

图 7 MRSA-1000 数据集上比较


4.3.3 CSSD 数据集

图 8(a)、8(b)所示是在 CSSD 数据集上的对比结果。虽然相对于 MRSA 数据集而言, CSSD 数据集更具有挑战性, 但从对比结果来看, 本文算法还



(a) PR 曲线

是具有一定的优势。从 PR 曲线上看本文方法更优越, 而且有更高的 Precision 与 F-measure 值和较低的 Recall 值。

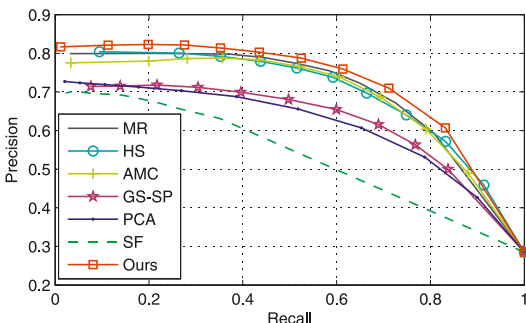


(b) 指标直方图

图 8 CSSD 数据集上比较


4.3.4 ECSSD 数据集

图 9(a)、9(b)所示是本文算法在 ECSSD 数据集上的对比实验结果。从 PR 曲线上看, 本文算法最



(a) PR 曲线

优。综合比较 3 个指标, 本文算法有最高的 Precision 值和 F-measure 值以及较低的 Recall 值。



(b) 指标直方图

图 9 ECSSD 数据集上比较

4.3.5 质量比较

图 10 显示本文算法和其他算法的视觉质量比较。前 3 行图像来自 MSRA-1000 数据集, 第 4 行图像是 CSSD 数据集上的, 最后 2 行图像来自

ECSSD 数据集。相对其他算法而言, 本文算法能很好地处理背景复杂图像, 同时在处理背景简单的图像时保持健壮性。




图 10 质量比较

5 结束语

不同于前人关注显著目标, 提取显著目标具有的特征, 并以此进行显著目标检测, 本文综合考虑目标和背景。在考虑“目标在哪儿”的同时, 运用“背景在哪儿”的信息将背景剔除。由于不同目标之间具有差异性, 若仅考虑目标特征往往适应性不足, 不同情况下会出现多检或漏检的问题。而“背景在哪儿”是考虑背景的特征, 为显著目标的检测提供补充信息。“目标在哪儿”、“背景在哪儿”的检测框架更具有显著目标检测的普遍性与完整性, 而实验证明本文算法具有更高的准确率。

其次, 基于特征融合的显著目标检测方法一般都是启发式的, 本文提出“目标在哪儿”与“背景在哪儿”的检测框架, 结合颜色区别性特征与边界先验特征, 这两种特征的使用能够互相补充, 但是它们的结合并不是固定的。

另外从 ECSSD 数据集上的评估结果来看, 虽然本文算法优于其他算法, 但是准确率还是有提高的余地。这说明在处理自然图像时仍然具有挑战性。“目标在哪儿”、“背景在哪儿”的检测框架还需要进一步优化, 可以考虑增加权重或阈值或者考虑使用不同特征。

显著目标检测可以准确提取图像中重要区域, 这种思想可以应用在视频中, 可以对视频进行预处理剔除冗余信息, 提高视频目标检测的实时性, 这对于视频目标检测具有重要意义。未来研究工作中将继续考虑显著目标检测在视频目标检测中的应用。

参考文献:

- [1] C. Koch and S. Ullman. Shifts in selective visual attention: towards the underlying neural circuitry. *Human neurobiology*, 4(4):219–227, 1985.
- [2] L. Itti, C. Koch, and E. Niebur. model of saliency-based visual attention for rapid scene analysis. *PAMI*, 20(11):1254–1259, 1998.
- [3] R. Achanta, S. Hemami, F. Estrada, and S. S. Süstrunk. Frequency tuned salient region detection. In *CVPR*, 1597–1604, 2009.
- [4] M. M. Cheng, G. X. Zhang, N. J. Mitra, X. Huang, and S. M. Hu. Global contrast based salient region detection. In *CVPR*, 2011.
- [5] Stas Goferman, Lihi Zelnik-Manor, and Ayellet Tal. Context-aware saliency detection. In *CVPR*, pages 2376–2383. in IEEE, 2010.
- [6] T. Liu, Z. Yuan, J. Sun, J. Wang, N. Zheng, X. Tang, and H. Y. Shum. Learning to detect a salient object. In *PAMI*, 33(2):353–367, 2011.
- [7] R. Achanta, F. Estrada, P. Wils, and S. Süstrunk. Salient region detection and segmentation. In *ICVS*, 2008.
- [8] J. Harel, C. Koch, and P. Perona. Graph-based visual saliency. In *NIPS*, 2006.
- [9] Y. Wei, F. Wen, W. Zhu, and J. Sun. Geodesic saliency using background priors. In *ECCV*, 2012.

- [10] H. Jiang, J. Wang, Z. Yuan, Y. Wu, N. Zheng, and S. Li. Salient object detection: A discriminative regional feature integration approach. In CVPR, 2013.
- [11] C. Yang, L. Zhang, H. Lu, X. Ruan, and M.-H. Yang. Saliency detection via graph-based manifold ranking. In CVPR, 2013.
- [12] A. Borji, D. N. Sihite, and L. Itti. Salient Object Detection: A Benchmark. In ECCV, 2012.
- [13] H. Jiang, J. Wang, Z. Yuan, T. Liu, N. Zheng, and S. Li. Automatic salient object segmentation based on context and shape prior. In BMVC, page 7, 2012.
- [14] D. Zhou, J. Weston, A. Gretton, O. Bousquet, and B. Scholkopf. Ranking on data manifolds. In NIPS, 2004.
- [15] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Süsstrunk. Slic superpixels. Technical Report 149300 EPFL, (June),2010.
- [16] B. Alexe, T. Deselaers, and V. Ferrari. Measuring the objectness of image windows. PAMI, 2012.
- [17] Q. Yan, L. Xu, J. Shi, and J. Jia. Hierarchical saliency detection. In CVPR, 2013.
- [18] B. Jiang, L. Zhang, H. Lu, C. Yang, and M. H. Yang. Saliency Detection via Absorbing Markov Chain. In ICCV, 2013.
- [19] R. Margolin, A. Tal, and L. Z. Manor. What makes a path distinct? In CVPR, 2014.
- [20] F. Perazzi, P. Krahenbuhl, Y. Pritch, and A. Hornung. Saliency filters: Contrast based filtering for salient region detection. In CVPR, 2012.
- [21] M. M. Cheng, J. Warrell, W. Y. Lin, S. Zheng, V. Vineet, and N. Crook. Efficient Salient Region Detection with Soft Image Abstraction. In ICCV, 2013.
- [22] P. Jiang, H. Ling, J. Yu, and J. Peng. Salient Region Detection by UFO: Uniqueness, Focusness and Objectness. In ICCV, 2013.
- [23] K. Chang, T. Liu, H. Chen, and S. Lai. Fusing generic objectness and visual saliency for salient object detection. In ICCV, pages 914–921. 2011.